

7 회

지역별 부동산 가격 예측 [문제]

🔗 **과제** : 고객 데이터 기반 대출 승인 여부 예측 AI 모델 개발

🔗 **도메인** : 금융

🔗 **배경**

금융 기관에서 대출 승인 심사는 리스크 관리의 핵심적인 부분입니다. 'AICE 캐피탈'의 리스크 관리팀은 과거 대출 신청 고객들의 데이터를 분석하여, 어떤 요인이 대출 승인 및 거절에 영향을 미치는지 파악하고자 합니다. 이를 바탕으로 신규 대출 신청 건에 대해 승인 가능성을 자동으로 예측하는 AI 모델을 개발하는 것이 목표입니다. 이 모델은 심사 과정의 효율성을 높이고, 일관성 있는 의사결정을 내리는 데 도움을 줄 것입니다.

데이터셋 설명(파일명: 7_loan_approval.csv)

컬럼 명	설명
employment_type	고용 형태
annual_income	연소득(만원)
credit_score	신용 점수
loan_purpose	대출 목적
loan_amount	대출 신청 금액(만원)
dti	부채 비율(%)
years_employed	고용 기간(년)
home_ownership	주택 소유 여부
delinquency_history	과거 연체 이력 유무
loan_status	예측 목표(Target), 대출 승인 여부 (1: 승인, 0: 거절)

[사전 실행 지시사항]

- 모든 문제를 풀기 전에 아래 코드를 실행해주세요.

```
In [ ]: # 데이터 분석 및 시각화에 필요한 기본 라이브러리들을 불러옵니다.
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
```

```
# Scikit-learn 라이브러리에서 필요한 모듈들을 불러옵니다.
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler, LabelEncoder
from sklearn.linear_model import LogisticRegression
from sklearn.ensemble import AdaBoostClassifier
from sklearn.metrics import accuracy_score, f1_score, confusion_matrix

# TensorFlow Keras 라이브러리를 불러옵니다.
import tensorflow as tf
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense
```

01

Scikit-learn 라이브러리의 ensemble 모듈에는 여러 개의 약한 학습기를 결합하여 성능을 높이는 앙상블 모델들이 포함되어 있습니다. sklearn.ensemble 모듈에서 AdaBoostClassifier 클래스를 임포트하는 코드를 작성하세요.

In []: # 여기에 답안코드를 작성하세요

02

AI 모델링을 위해 분석할 데이터를 준비하고 기본적인 정보를 파악하려고 합니다. 아래 가이드에 따라 코드를 작성하세요.

- Pandas의 read_csv 함수를 사용하여 7_loan_approval.csv 파일을 읽어 데이터프레임 변수 loan_df에 할당하세요.
- info() 함수를 사용하여 loan_df의 요약 정보를 확인하여 결측치와 데이터 타입을 파악하세요.

In []: # 여기에 답안코드를 작성하세요

03

신용점수(credit_score)가 대출승인여부(loan_status)에 따라 어떻게 다른 분포를 보이는지 시각적으로 탐색하고자 합니다. seaborn의 violinplot을 사용하여 두 그룹의 credit_score 분포를 비교하세요.

- x축: loan_status
- y축: credit_score
- 데이터: loan_df

In []: # 여기에 답안코드를 작성하세요

04

주택소유여부(home_ownership)에 따른 대출 승인 고객의 비율을 확인하려고 합니다. pandas의 crosstab 함수를 사용하여 두 변수의 교차표를 생성하고, normalize='index' 옵션을 사용하여 각 주택 소유 그룹 내에서 대출 승인/거절 비율을 계산하세요.

In []: # 여기에 답안코드를 작성하세요

05

고용형태(employment_type)별로 연소득(annual_income)과 대출금액(loan_amount)의 평균을 비교하고자 합니다. groupby()를 사용하여 데이터를 employment_type으로 그룹화하고, 두 변수의 평균을 계산하세요.

In []: # 여기에 답안코드를 작성하세요

06

모델링을 위해 데이터의 결측치를 처리하려고 합니다. 아래 가이드에 따라 결측치를 처리하고, 결과를 loan_pre 변수에 저장하세요.

- loan_df 데이터프레임을 복사하여 loan_pre를 생성합니다.
- 수치형 컬럼인 annual_income, credit_score, loan_amount, dti, years_employed의 결측치는 각 컬럼의 중앙값(median)으로 채우세요.
- 범주형 컬럼인 employment_type, loan_purpose, home_ownership의 결측치는 각 컬럼의 최빈값(mode)으로 채우세요.

In []: # 여기에 답안코드를 작성하세요

07

모델이 이해할 수 있도록 범주형 데이터를 수치형으로 변환하려고 합니다. 아래 가이드에 따라 두 가지 다른 방식으로 인코딩을 수행하세요.

- 값이 두 개인 home_ownership과 delinquency_history 컬럼은 sklearn.preprocessing의 LabelEncoder를 사용하여 레이블 인코딩을 수행하세요.
- 값이 여러 개인 employment_type과 loan_purpose 컬럼은 pandas의 get_dummies()를 사용하여 원-핫 인코딩을 수행하세요.
- 모든 변환은 loan_pre 데이터프레임에 직접 적용하세요.

```
In [ ]: # 여기에 답안코드를 작성하세요
```

08

훈련과 검증에 사용할 데이터셋을 분리하려고 합니다. loan_status 컬럼을 label y로, 나머지 컬럼들을 feature X로 할당한 후 훈련 데이터셋과 검증 데이터셋으로 분리하는 코드를 작성하세요.

- 대상 데이터셋: loan_pre(7번 문제까지 처리 완료된)
- 훈련: 검증 데이터 비율: 70:30
- random_state: 2024
- 추가 옵션: stratify=y를 사용하여 타겟 변수의 분포를 유지

```
In [ ]: # 여기에 답안코드를 작성하세요
```

09

수치형 데이터들의 단위를 맞춰주기 위해 데이터 스케일링을 진행합니다. 평균을 0, 표준편차를 1로 변환하는 StandardScaler를 사용하여 훈련 데이터와 검증 데이터의 Feature(X_{train} , X_{valid})를 스케일링하는 코드를 작성하세요.

- 훈련 데이터에는 `fit_transform()`을, 검증 데이터에는 `transform()`을 적용하세요.
- 스케일링된 결과는 각각 `X_train_scaled`, `X_valid_scaled` 변수에 저장하세요.

In []: # 여기에 답안코드를 작성하세요

10

가장 기본적인 이진 분류 모델인 LogisticRegression을 사용하여 대출 승인 예측 모델을 학습시키려고 합니다. 아래 가이드에 따라 모델을 생성하고 학습시키는 코드를 작성하세요.

- `sklearn.linear_model`의 LogisticRegression 함수 사용
- 하이퍼파라미터 설정: `random_state=2024`
- 모델 객체는 `model_lr` 변수에 저장하고, 스케일링된 훈련 데이터로 학습시키세요.

In []: # 여기에 답안코드를 작성하세요

11

이번에는 AdaBoostClassifier 모델을 사용하여 학습을 진행하려고 합니다. 아래 가이드에 따라 모델을 학습시키고, 검증 데이터셋(X_valid_scaled)에 대한 예측 결과를 ada_pred 변수에 저장하세요.

- sklearn.ensemble의 AdaBoostClassifier 함수 사용(1번 문제에서 임포트)
- 하이퍼파라미터 설정
 - ▶ n_estimators: 50
 - ▶ learning_rate: 1.0
 - ▶ random_state: 2024
- 모델 객체는 model_ada 변수에 저장하고 학습시키세요.

In []: # 여기에 답안코드를 작성하세요

12

앞서 학습한 AdaBoostClassifier 모델(model_ada)의 성능을 평가하려고 합니다. 분류 모델의 성능을 종합적으로 평가하는 지표인 F1 Score를 계산하고, 혼동 행렬(Confusion Matrix)을 시각화하는 코드를 작성하세요.

- sklearn.metrics에서 f1_score, confusion_matrix 함수를 import하세요.
- model_ada를 사용하여 예측 결과를 생성한 후, F1 Score를 계산하여 출력하세요.
- seaborn의 heatmap을 사용하여 혼동 행렬을 시각화하세요.

In []: # 여기에 답안코드를 작성하세요

13

이번에는 딥러닝을 사용하여 대출 승인 예측 모델을 만들려고 합니다. 아래의 가이드에 따라 tensorflow, keras를 사용하여 이진 분류 모델을 구축하고 학습시키세요.

- Sequential 모델을 사용하세요.
- 모델 구조
 - ▶ 입력층: Dense 레이어, 16개 노드, 활성화 함수 relu
 - ▶ 은닉층 1: Dense 레이어, 8개 노드, 활성화 함수 relu
 - ▶ 출력층: Dense 레이어, 1개 노드, 활성화 함수 sigmoid
- 컴파일 설정
 - ▶ optimizer: adam
 - ▶ loss: binary_crossentropy
 - ▶ metrics: ['accuracy']
- 학습 설정
 - ▶ epochs: 20
 - ▶ batch_size: 64
- validation_data로 X_valid_scaled, y_valid를 사용하여 검증 성능도 함께 확인하세요.
- 학습 과정은 history 변수에 저장하세요.

```
In [ ]: # 여기에 답안코드를 작성하세요
```


14

최종적으로 완성된 딥러닝 모델을 사용하여, 아래와 같은 새로운 고객 데이터가 들어왔을 때의 대출 승인 확률을 예측하려고 합니다. 주어진 시뮬레이션 데이터(new_applicant_data)를 9번 문제에서 생성한 스케일러(scaler)를 사용하여 변환한 뒤, 딥러닝 모델로 승인 확률을 예측하는 코드를 작성하세요.

- 예측 결과(확률값)는 predicted_approval_prob 변수에 저장하세요.
- 아래 코드를 실행하여 시뮬레이션용 데이터를 생성하세요.

```
In [ ]: new_applicant_data = np.array([[10000, 750, 5000, 150, 5, 1, 0, 0, 0, 1, 0, 0, 1]])
```

```
In [ ]: # 여기에 답안코드를 작성하세요
```